


RAGの基本概念

目的	検索した文書を回答の根拠としてLLMへ渡す
用途	社内手順や更新される技術文書を参照する
仕組み	質問と関連文書を組み合わせて回答を生成する
限界	検索漏れや誤った文書で回答品質が低下する
運用	文書更新を索引へ反映し、根拠と回答を確認する

RAG全体構成：役割と受け渡し


構成要素	入力	出力・責務
取り込み処理	文書・版・アクセス権	チャンク・ベクトルを登録
検索インデックス	本文・ベクトル・属性	関連文書を検索可能にする
検索・制御層	質問・利用者の権限	許可された関連文書を選ぶ
LLM	質問・検索結果	回答を生成する
アプリケーション	回答・参照元	根拠を提示し評価を収集

文書の取り込みとベクトル化



直列の処理概要。更新・削除時の索引同期は別途設計する。

検索と回答生成の手順



基本順序。権限の適用は検索・文脈構成の両段階で確認する。

検索品質と回答品質を分けて評価

	検索の評価	回答の評価
対象	必要な根拠を取得できたか	質問に答え、根拠に忠実か
評価資料	質問と正解文書を用意する	回答・検索文脈・期待結果を確認
不具合	チャンク、索引、検索条件を調べる	根拠不足、指示、モデルを調べる
比較方法	同じ質問集合で変更前後を比較	人の確認を併用する

RAGのセキュリティ設計

アクセス権

利用者に許可された文書だけを検索する

信頼境界

検索文書中の指示を実行命令にしない

情報保護

転送・保存を暗号化し、出力の機密性を確認する

取り込み

悪意ある文書を検査し、出典を追跡する

監査

質問・ログの保存範囲を定め、権限と保持期限を管理する

RAGの運用監視

観測点	見る情報	改善につなげる確認
取り込み	失敗・最終同期時刻	更新漏れと抽出結果を確認
検索	検索結果・参照文書	根拠の欠落と権限を確認
回答	根拠との一致・評価	検索と生成の問題を分ける
性能・費用	遅延・利用量	処理区間ごとに計測する
データ管理	文書の版・削除状況	索引と元資料の対応を追う

RAG導入で先に確認すること

- 01 根拠文書・権限・更新方法を決める
- 02 検索と回答を別々に評価する
- 03 出典を追跡し、機密情報を守る

次の行動

小さな質問集合で根拠と回答を確認し、改善を重ねる。